

统计方法与机器学习

第三章 多重共线性及其解决方案

倪 蓓

Dase@ECNU

什么是主成分回归？

主成分回归 = 主成分分析 + 回归分析



关键问题

1. 基于主成分，如何求回归系数 β 的主成分估计？
2. 主成分估计 $\hat{\beta}_{PC}$ 与最小二乘估计 $\hat{\beta}$ 有什么关系？

目录

3. 主成分回归 (Multicollinearity)

I. 主成分分析

II. 主成分估计

III. 主成分估计的性质

IV. 超参数选择

目录

3. 主成分回归 (Multicollinearity)

I. 主成分分析


II. 主成分估计

III. 主成分估计的性质

IV. 超参数选择

问题定义


- 主成分分析是一种经典的降维方法。
- 提问：为什么要降维？



- 不同变量之间的信息是重叠的，降维能够有效地抽取有用的信息。

问题定义

- 主成分分析是一种经典的**降维**方法。
- 提问：与变量选择相比，主成分分析是如何实现降维的？
- 变量选择**：保留原始的变量作为特征；
- 主成分分析**：构建全新的变量作为特征。
- 提问：如何确定 $\mathbf{a}_j = (a_{1j}, a_{2j}, \dots, a_{pj})^\top$



$$z_{ij} = a_{1j}x_{i1} + a_{2j}x_{i2} + \cdots + a_{pj}x_{ip}$$


基本方法

- 设一个 p 维随机向量

$$\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$$

- 其期望为 $E(\mathbf{x}) = \boldsymbol{\mu}$;
- 其方差-协方差矩阵为 $\text{Var}(\mathbf{x}) = \boldsymbol{\Sigma}$ 。
- 考虑 $\mathbf{x}$ 的一个线性变换，即

$$z_j = \mathbf{a}_j^\top \mathbf{x} = a_{1j}x_1 + a_{2j}x_2 + \dots + a_{pj}x_p$$


$$\mathbf{a}_j = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{pj} \end{pmatrix}$$

- 显然，

$$\text{Var}(z_j) = \text{Var}(\mathbf{a}_j^\top \mathbf{x}) = \mathbf{a}_j^\top \boldsymbol{\Sigma} \mathbf{a}_j$$

$$\text{Cov}(z_j, z_{j'}) = \text{Cov}(\mathbf{a}_j^\top \mathbf{x}, \mathbf{a}_{j'}^\top \mathbf{x}) = \mathbf{a}_j^\top \boldsymbol{\Sigma} \mathbf{a}_{j'}$$

基本方法

- 若用一个新特征 z 代替原本的 p 维特征 $x_1, x_2, \dots, x_p$, 则 z_1 需要尽可能多地反映原本的信息。
- 提问：如何度量 p 维特征的信息量？
- 在统计学中，常采用“**方差**”来度量数据的信息量。




基本方法

- 若用一个新特征 z 代替原本的 p 维特征 $x_1, x_2, \dots, x_p$, 则 z_1 需要尽可能多地反映原本的信息。
- 提问：如何度量 p 维特征的信息量？
- 在统计学中，常采用“**方差**”来度量数据的信息量。



基本方法

- 若用一个新特征 z 代替原本的 p 维特征 $x_1, x_2, \dots, x_p$, 则 z_1 需要尽可能多地反映原本的信息。
- 提问：如何度量 p 维特征的信息量？
- 在统计学中，常采用“**方差**”来度量数据的信息量。



基本方法

- 若用一个新特征 z 代替原本的 p 维特征 $x_1, x_2, \dots, x_p$, 则 z_1 需要尽可能多地反映原本的信息。
- 提问：如何度量 p 维特征的信息量？
- 在统计学中，常采用“**方差**”来度量数据的信息量。
- 具体来说， z 的方差为

$$\text{Var}(z) = \text{Var}(\mathbf{a}^\top \mathbf{x}) = \mathbf{a}^\top \mathbf{\Sigma} \mathbf{a}$$

- 于是，想要找到合适的 $\mathbf{a}$ 满足

$$\mathbf{a} = \operatorname{argmax} \mathbf{a}^\top \mathbf{\Sigma} \mathbf{a}$$

基本方法

- 对于任意的向量 $\mathbf{a}$, 令 $\mathbf{a}' = 2\mathbf{a}$, 有

$$(\mathbf{a}')^\top \Sigma (\mathbf{a}') = 4\mathbf{a}^\top \Sigma \mathbf{a} > \mathbf{a}^\top \Sigma \mathbf{a}$$

- 为避免向量的模所造成的影响 , 仅考虑单位向量 , 即

$$\mathbf{a}^\top \mathbf{a} = 1$$

- 因此 , 想要找到合适的 $\mathbf{a}$ 满足

$$\mathbf{a} = \operatorname{argmax} \mathbf{a}^\top \Sigma \mathbf{a}$$

使得

$$\mathbf{a}^\top \mathbf{a} = 1$$

- 记所得到的向量为 $\mathbf{a}_1$, 并称 $z_1 = \mathbf{a}_1^\top \mathbf{x}$ 为**第一主成分**。

基本方法

- 倘若第一主成分不足以代表所有特征的信息，则需要考虑第二主成分 $z_2 = \mathbf{a}_2^\top \mathbf{x}$ 。
- 同时，希望不同主成分之间的信息不重叠。从统计学的角度来看，即要求

$$\text{Cov}(z_1, z_2) = \mathbf{a}_2^\top \mathbf{\Sigma} \mathbf{a}_1 = 0$$

- 于是，想要找第二主成分中的 $\mathbf{a}_2$ ，需要满足

$$\mathbf{a}_2 = \operatorname{argmax} \mathbf{a}_2^\top \mathbf{\Sigma} \mathbf{a}_2$$

使得

$$\mathbf{a}_2^\top \mathbf{a}_2 = 1 \text{ 且 } \mathbf{a}_2^\top \mathbf{\Sigma} \mathbf{a}_1 = 0$$

- 类似地，可以求第三主成分、第四主成分、...

定义

- 设一个 p 维随机向量 $\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$ 和一个 p 维常数向量 $\mathbf{a}_j = (a_{1j}, a_{2j}, \dots, a_{pj})^\top$ 。如果

$$z_j = \mathbf{a}_j^\top \mathbf{x}$$

是 $\mathbf{x}$ 的线性组合，且满足

$$\text{Var}(z_j) = \max_{\substack{\mathbf{a}^\top \mathbf{a} = 1 \\ \mathbf{a}^\top \text{Var}(\mathbf{x}) \mathbf{a}_{j'} = 0, j' = 1, \dots, j}} \text{Var}(\mathbf{a}^\top \mathbf{x})$$

那么，称 z_j 为 $\mathbf{x}$ 的第 j 个主成分。

基本方法：以第一主成分为例

- 设一个 p 维随机向量 $\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$
 - 期望为 $E(\mathbf{x}) = 0$;
 - 方差-协方差矩阵为 $\text{Var}(\mathbf{x}) = \Sigma$ 。
- 提问：如何求第一主成分 $z_1 = \mathbf{a}_1^\top \mathbf{x}$?
- 根据定义, $\mathbf{a}_1 = (a_{11}, a_{12}, \dots, a_{p1})^\top$ 满足

$$\mathbf{a}_1 = \operatorname{argmax}_{\mathbf{a}} \text{Var}(\mathbf{a}^\top \mathbf{x})$$

使得

$$\mathbf{a}^\top \mathbf{a} = 1$$

基本方法：以第一主成分为例

- 带约束的最优化问题可以采用拉格朗日乘子法。

- 令

$$l(\mathbf{a}) = \text{Var}(\mathbf{a}^\top \mathbf{x}) - \lambda(\mathbf{a}^\top \mathbf{a} - 1) = \mathbf{a}^\top \mathbf{\Sigma} \mathbf{a} - \lambda(\mathbf{a}^\top \mathbf{a} - 1)$$

- 于是有

$$\begin{cases} \frac{\partial l}{\partial \mathbf{a}} = 2(\mathbf{\Sigma} - \lambda \mathbf{I})\mathbf{a} = 0 \\ \frac{\partial l}{\partial \lambda} = -(\mathbf{a}^\top \mathbf{a} - 1) = 0 \end{cases}$$

- 因为 $\mathbf{\Sigma} \mathbf{a} = \lambda \mathbf{a}$, 所以 , λ 和 $\mathbf{a}$ 分别是 $\mathbf{\Sigma}$ 的特征值和特征向量。
- 类似地 , 求解主成分问题等价于求 $\mathbf{\Sigma}$ 的特征值和特征向量的问题。

定义

- 设一个 p 维随机向量 $\mathbf{x} = (x_1, x_2, \dots, x_p)^\top$ 的方差-协方差矩阵为 $\text{Var}(\mathbf{x}) = \mathbf{\Sigma}$ 。如果
 - $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ 是 $\mathbf{\Sigma}$ 的特征值；
 - $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 为相应的单位正交特征向量；

那么，称

$$z_j = \mathbf{v}_j^\top \mathbf{x}, j = 1, 2, \dots, p$$

为 $\mathbf{x}$ 的第 j 个主成分。

- 令 $\mathbf{z} = (z_1, z_2, \dots, z_p)^\top$ 和 $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_p\}$ 。则

$$\text{Var}(\mathbf{z}) = \mathbf{\Lambda}。$$

讨论：量纲对主成分的影响

- 考虑以下两个方差-协方差矩阵：

$$\Sigma_1 = \begin{pmatrix} 100 & 5 \\ 5 & 1 \end{pmatrix}$$

特征值	$\lambda_1 = 100.25$	$\lambda_2 = 0.75$
特征向量	$v_1 = \begin{pmatrix} 0.9987 \\ 0.0503 \end{pmatrix}$	$v_2 = \begin{pmatrix} -0.0503 \\ 0.9987 \end{pmatrix}$

和

$$\Sigma_2 = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

特征值	$\lambda_1 = 1.5$	$\lambda_2 = 0.5$
特征向量	$v_1 = \begin{pmatrix} 0.7071 \\ 0.7071 \end{pmatrix}$	$v_2 = \begin{pmatrix} -0.7071 \\ 0.7071 \end{pmatrix}$

- 根据方差-协方差矩阵来求主成分，优先考虑方差大的特征。
- 有时，特征的量纲不同，导致特征方差存在差异。
- 为消除量纲的影响，用相关阵 $\text{Corr}(\mathbf{x})$ 代替方差-协方差矩阵 $\text{Var}(\mathbf{x})$ 来计算主成分。

总结

- 主成分分析的目的是找到原始特征的合适线性组合，即

$$z_j = \mathbf{a}_j^\top \mathbf{x}$$

- 求主成分的问题可以转化为求方差-协方差矩阵 $\text{Var}(\mathbf{x})$ 的特征值和特征向量。
- 有时，为避免量纲的影响，求相关阵 $\text{Corr}(\mathbf{x})$ 的特征值和特征向量。

目录

3. 主成分回归 (Multicollinearity)

I. 主成分分析

II. 主成分估计

III. 主成分估计的性质

IV. 超参数选择

概述

- 在主成分回归模型中，参数的估计步骤为
 - 确定主成分 $z_1, z_2, \dots, z_q (q < p)$ ；
 - 将主成分代替原本的特征构建回归模型，得到回归系数估计 $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_q$ ；
 - 通过参数估计 $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_q$ 来确定原本特征的回归系数估计 $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p$ 。
- 在主成分回归模型中，假定
 - 特征是经过标准化；
 - 标签是经过中心化。

主成分的计算方法

- 考虑设计矩阵为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{pmatrix}$$

- 样本方差-协方差矩阵 $\mathbf{S}$ 为

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = \{s_{jj'}\}$$

$$\bar{\mathbf{x}} = \sum_{i=1}^n \mathbf{x}_i = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{pmatrix}$$

注意到

$$s_{jj'} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ij'} - \bar{x}_{j'})$$

主成分的计算方法

- 相关阵 R 为

$$R = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

其中，

$$r_{jj'} = \frac{s_{jj'}}{\sqrt{s_{jj}s_{j'j'}}}$$

主成分的计算方法

- 经标准化后，设计矩阵为

$$\mathbf{X}_s = \begin{pmatrix} x_{11}^{**} & x_{12}^{**} & \cdots & x_{1p}^{**} \\ x_{21}^{**} & x_{22}^{**} & \cdots & x_{2p}^{**} \\ \vdots & \vdots & & \vdots \\ x_{n1}^{**} & x_{n2}^{**} & \cdots & x_{np}^{**} \end{pmatrix}$$

- 注意到， x_{ij}^{**} 和 x_{ij} 之间的关系为

$$x_{ij}^{**} = \frac{x_{ij} - \bar{x}_j}{\sqrt{l_{jj}}}$$

其中，

$$l_{jj} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 = (n-1)s_{jj}$$

主成分的计算方法

- 以下证明： $X_s^\top X_s = R$ 。
- 在 $X_s^\top X_s$ 中，每个元素为

$$\sum_{i=1}^n x_{ij}^{**} x_{ij'}^{**} = \sum_{i=1}^n \frac{x_{ij} - \bar{x}_j}{\sqrt{l_{jj}}} \times \frac{x_{ij'} - \bar{x}_{j'}}{\sqrt{l_{j'j'}}} = \sum_{i=1}^n \frac{s_{jj'}}{\sqrt{s_{jj}s_{j'j'}}} = r_{jj'}$$

- 以下将 X_s 记为 X 。（备注：假定 X 是经过标准化的）

主成分的计算方法

- 假定 $\mathbf{X}^\top \mathbf{X}$ 的
 - 特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$;
 - 其相应单位正交特征向量为 $\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_p$ 。

• 令

$$\Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_p \end{pmatrix}$$
$$\mathbf{V}^\top = (\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_p)$$

• 易知

$$\mathbf{v}_j^\top \mathbf{v}_{j'} = \begin{cases} 1 & j = j' \\ 0 & j \neq j' \end{cases}$$

$$\mathbf{V}\mathbf{V}^\top = \mathbf{V}^\top\mathbf{V} = \mathbf{I}$$

$$(\mathbf{X}^\top \mathbf{X})\mathbf{v}_j = \lambda_j \mathbf{v}_j, j = 1, 2, \cdots, p$$

• 特征值分解为

$$\mathbf{X}^\top \mathbf{X} = \mathbf{V}^\top \Lambda \mathbf{V}$$

也就是说，

$$\mathbf{V}(\mathbf{X}^\top \mathbf{X})\mathbf{V}^\top = (\mathbf{X}\mathbf{V}^\top)^\top (\mathbf{X}\mathbf{V}^\top) = \Lambda$$

主成分的计算方法

$$(XV^T)^T(XV^T) = \Lambda$$

- 令

$$Z = XV^T$$

- 于是有

$$Z^T Z = \Lambda$$

- 记

$$Z = (z_1 \quad z_2 \quad \cdots \quad z_p)$$

且

$$z_j = Xv_j = v_{1j}x_1 + v_{2j}x_2 + \cdots + v_{pj}x_p$$

- 注意到

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} = (x_1 \quad x_2 \quad \cdots \quad x_p)$$

有

$$\mathbf{1}_n^T x_j = 0 \text{ 且 } x_j^T x_j = 1, j = 1, 2, \cdots, p$$

- 于是，

$$\mathbf{1}_n^T z_j = 0 \text{ 且 } z_j^T z_{j'} = \begin{cases} \lambda_j & j = j' \\ 0 & j \neq j' \end{cases}$$

z_j 之间相互正交；若 $\lambda_j \approx 0$ ，则 $z_j \approx 0$

回归系数 α 的计算方法

- 假定 y 是经过中心化的。
- 线性回归模型为

$$y = X\beta + \varepsilon = XV^{\top}V\beta + \varepsilon = Z\alpha + \varepsilon$$

- 若存在 q 使得 $\lambda_{q+1}, \dots, \lambda_p$ 接近 0 , 则 $z_{q+1}, \dots, z_p$ 接近 0。
- 将矩阵 Z 和向量 α 按以下方式进行拆分：

$$Z = (z_1 \quad \cdots \quad z_q \quad z_{q+1} \quad \cdots \quad z_p) = (Z_1 \quad Z_2)$$

$$\alpha = (\alpha_1 \quad \cdots \quad \alpha_q \quad \alpha_{q+1} \quad \cdots \quad \alpha_p)^{\top} = (\alpha_1^{\top} \quad \alpha_2^{\top})^{\top}$$

- 线性回归模型可以写为

$$y = Z\alpha + \varepsilon = Z_1\alpha_1 + Z_2\alpha_2 + \varepsilon = Z_1\alpha_1 + \varepsilon$$

回归系数 α 的计算方法

- 线性回归模型

$$\mathbf{y} = \mathbf{Z}_1 \boldsymbol{\alpha}_1 + \boldsymbol{\varepsilon}$$

- $\boldsymbol{\alpha}_1$ 的估计为

$$\hat{\boldsymbol{\alpha}}_1 = (\mathbf{Z}_1^\top \mathbf{Z}_1)^{-1} \mathbf{Z}_1^\top \mathbf{y}$$

- Λ 和 V 可以拆分为两个部分，即

$$\begin{aligned}\Lambda_1 &= \text{diag}\{\lambda_1, \dots, \lambda_q\} \\ \Lambda_2 &= \text{diag}\{\lambda_{q+1}, \dots, \lambda_p\}\end{aligned}$$

$$\Lambda = \begin{pmatrix} \Lambda_1 & \\ & \Lambda_2 \end{pmatrix} \quad \text{和} \quad V^\top = (V_1^\top \quad V_2^\top)$$

$$\begin{aligned}V_1^\top &= (\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_q) \\ V_2^\top &= (\mathbf{v}_{q+1} \quad \cdots \quad \mathbf{v}_p)\end{aligned}$$

- 于是有

$$\hat{\boldsymbol{\alpha}}_1 = \Lambda_1^{-1} \mathbf{Z}_1^\top \mathbf{y}$$

回归系数 β 的计算方法

- 由于

$$\hat{\alpha}_1 = \Lambda_1^{-1} \mathbf{Z}_1^\top \mathbf{y}$$

而且

$$\alpha = V\beta$$

- 于是，

$$\beta = V^\top \alpha$$

- 用零补全，即 $\hat{\alpha} = \begin{pmatrix} \hat{\alpha}_1 \\ \mathbf{0} \end{pmatrix}$ ，则称

$$\hat{\beta}_{\text{PC}} = V^\top \begin{pmatrix} \hat{\alpha}_1 \\ \mathbf{0} \end{pmatrix} = V_1^\top \hat{\alpha}_1 = V_1^\top \Lambda_1^{-1} \mathbf{Z}_1^\top \mathbf{y}$$

为 β 的主成分估计。

总结

- 线性回归模型为

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} = \mathbf{Z}_1\boldsymbol{\alpha}_1 + \boldsymbol{\varepsilon}$$

- 第一步：计算 $\mathbf{X}^\top \mathbf{X}$ 的特征值 $\boldsymbol{\Lambda} = \text{diag}\{\lambda_1, \dots, \lambda_p\} = \begin{pmatrix} \boldsymbol{\Lambda}_1 & \\ & \boldsymbol{\Lambda}_2 \end{pmatrix}$ 和特征向量 $\mathbf{V}^\top = (\mathbf{v}_1, \dots, \mathbf{v}_p) = (\mathbf{V}_1^\top \quad \mathbf{V}_2^\top)$ 。
- 第二步：计算主成分 $\mathbf{Z}_1 = (\mathbf{z}_1, \dots, \mathbf{z}_q)$ ，其中 $\mathbf{z}_j = \mathbf{X}\mathbf{v}_j$ ， $j = 1, 2, \dots, q$ 。
- 第三步：计算回归系数的估计 $\hat{\boldsymbol{\alpha}}_1 = \boldsymbol{\Lambda}_1^{-1} \mathbf{Z}_1^\top \mathbf{y}$ 。
- 第四步：得到回归系数的主成分估计 $\hat{\boldsymbol{\beta}}_{\text{PC}} = \mathbf{V}_1^\top \boldsymbol{\Lambda}_1^{-1} \mathbf{Z}_1^\top \mathbf{y}$

目录

3. 主成分回归 (Multicollinearity)

I. 主成分分析

II. 主成分估计

III. 主成分估计的性质

IV. 超参数选择

问题定义

- 最小二乘估计是**最优线性无偏估计**。
- 提问：当出现多重共线性时，为什么主成分估计优于最小二乘估计？

性质1：有偏估计

定理3.1 当 $q < p$ 时，主成分估计是有偏的。

定理3.1的证明

首先，证明以下引理： $\hat{\beta}_{\text{PC}} = V_1^T V_1 \hat{\beta}$ 。

$$\begin{aligned}\hat{\beta}_{\text{PC}} &= V_1^T \Lambda_1^{-1} Z_1^T y \\ &= V_1^T \Lambda_1^{-1} V_1 X^T y \\ &= V_1^T \Lambda_1^{-1} V_1 X^T X (X^T X)^{-1} X^T y \\ &= V_1^T \Lambda_1^{-1} V_1 X^T X \hat{\beta} \\ &= V_1^T \Lambda_1^{-1} V_1 V^T \Lambda V \hat{\beta} \\ &= V_1^T \Lambda_1^{-1} V_1 (V_1^T \quad V_2^T) \begin{pmatrix} \Lambda_1 & \\ & \Lambda_2 \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \end{pmatrix} \hat{\beta} \\ &= V_1^T V_1 \hat{\beta}\end{aligned}$$

性质1：有偏估计

定理3.1 当 $q < p$ 时，主成分估计是有偏的。

定理3.1的证明

首先，证明以下引理： $\hat{\beta}_{PC} = V_1^T V_1 \hat{\beta}$ 。

其次， $\hat{\beta}_{PC}$ 的期望为

$$E(\hat{\beta}_{PC}) = E(V_1^T V_1 \hat{\beta}) = V_1^T V_1 \beta$$

知识回顾

在多元线性回归模型中， β 的估计为

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

于是有， $\hat{\beta}$ 的期望为

$$E(\hat{\beta}) = \beta$$

性质1：有偏估计

定理3.1 当 $q < p$ 时，主成分估计是有偏的。

定理3.1的证明

首先，证明以下引理： $\hat{\boldsymbol{\beta}}_{\text{PC}} = \mathbf{V}_1^\top \mathbf{V}_1 \hat{\boldsymbol{\beta}}$ 。

其次， $\hat{\boldsymbol{\beta}}_{\text{PC}}$ 的期望为

$$E(\hat{\boldsymbol{\beta}}_{\text{PC}}) = E(\mathbf{V}_1^\top \mathbf{V}_1 \hat{\boldsymbol{\beta}}) = \mathbf{V}_1^\top \mathbf{V}_1 \boldsymbol{\beta}$$

注意到，虽然 $\mathbf{V}^\top \mathbf{V} = \mathbf{V}_1^\top \mathbf{V}_1 + \mathbf{V}_2^\top \mathbf{V}_2 = \mathbf{I}$

但是， $\mathbf{V}_1^\top \mathbf{V}_1$ 不是单位矩阵，而

$$\mathbf{V}_1^\top \mathbf{V}_1 = \mathbf{I} - \mathbf{V}_2^\top \mathbf{V}_2$$

所以，

$$\mathbf{V}_1^\top \mathbf{V}_1 \boldsymbol{\beta} = (\mathbf{I} - \mathbf{V}_2^\top \mathbf{V}_2) \boldsymbol{\beta} \neq \boldsymbol{\beta}$$

因此，定理得证。

性质2：在均方误差的意义下更优

若 β 是一个 p 维参数，而 $\hat{\beta}$ 是其估计。称

$$\text{MSE}(\hat{\beta}) = E(\hat{\beta} - \beta)^{\top} (\hat{\beta} - \beta)$$

为 $\hat{\beta}$ 的均方误差。

说明： $\text{MSE}(\hat{\beta})$ 不是 $\hat{\beta}$ 的方差-协方差矩阵，而是每一个分量的均方误差之和。

引理3.2 若 $\hat{\beta}$ 是最小二乘估计，则 $\text{MSE}(\hat{\beta}) = \sigma^2 \sum_{j=1}^p \lambda_j^{-1}$

引理3.3 若 $\hat{\beta}_{\text{PC}}$ 是主成分估计，则 $\text{MSE}(\hat{\beta}_{\text{PC}}) = \sigma^2 \sum_{j=1}^q \lambda_j^{-1} + \sum_{j=q+1}^p \alpha_j^2$

性质2：在均方误差的意义下更优

引理3.3的证明

$$\begin{aligned} \text{MSE}(\hat{\boldsymbol{\beta}}_{\text{PC}}) &= E(\hat{\boldsymbol{\beta}}_{\text{PC}} - \boldsymbol{\beta})^\top (\hat{\boldsymbol{\beta}}_{\text{PC}} - \boldsymbol{\beta}) \\ &= E\left(\mathbf{V}^\top \begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \mathbf{V}^\top \boldsymbol{\alpha}\right)^\top \left(\mathbf{V}^\top \begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \mathbf{V}^\top \boldsymbol{\alpha}\right) \\ &= E\left(\begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \boldsymbol{\alpha}\right)^\top \mathbf{V}\mathbf{V}^\top \left(\begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \boldsymbol{\alpha}\right) \\ &= E\left(\begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \begin{pmatrix} \boldsymbol{\alpha}_1 \\ \boldsymbol{\alpha}_2 \end{pmatrix}\right)^\top \left(\begin{pmatrix} \hat{\boldsymbol{\alpha}}_1 \\ \mathbf{0} \end{pmatrix} - \begin{pmatrix} \boldsymbol{\alpha}_1 \\ \boldsymbol{\alpha}_2 \end{pmatrix}\right) \end{aligned}$$

$$\hat{\boldsymbol{\alpha}}_1 = \boldsymbol{\Lambda}_1^{-1} \mathbf{Z}_1^\top \mathbf{y} = \boldsymbol{\Lambda}_1^{-1} \mathbf{Z}_1^\top (\mathbf{Z}_1 \boldsymbol{\alpha}_1 + \boldsymbol{\varepsilon})$$

$$\begin{aligned} &= E(\hat{\boldsymbol{\alpha}}_1 - \boldsymbol{\alpha}_1)^\top (\hat{\boldsymbol{\alpha}}_1 - \boldsymbol{\alpha}_1) + \boldsymbol{\alpha}_2^\top \boldsymbol{\alpha}_2 \\ &= E(\boldsymbol{\varepsilon}^\top \mathbf{Z}_1 \boldsymbol{\Lambda}_1^{-2} \mathbf{Z}_1^\top \boldsymbol{\varepsilon}) + \boldsymbol{\alpha}_2^\top \boldsymbol{\alpha}_2 \\ &= \sigma^2 \text{tr}(\boldsymbol{\Lambda}_1^{-1}) + \boldsymbol{\alpha}_2^\top \boldsymbol{\alpha}_2 \\ &= \sigma^2 \sum_{j=1}^q \lambda_j^{-1} + \sum_{j=q+1}^p \alpha_j^2 \end{aligned}$$

性质2：在均方误差的意义下更优

若 β 是一个 p 维参数，而 $\hat{\beta}$ 是其估计。称

$$\text{MSE}(\hat{\beta}) = E(\hat{\beta} - \beta)^{\top}(\hat{\beta} - \beta)$$

为 $\hat{\beta}$ 的均方误差。

说明： $\text{MSE}(\hat{\beta})$ 不是 $\hat{\beta}$ 的方差-协方差矩阵，而是每一个分量的均方误差之和。

引理3.2

若 $\hat{\beta}$ 是最小二乘估计，则 $\text{MSE}(\hat{\beta}) = \sigma^2 \sum_{j=1}^q \lambda_j^{-1} + \sigma^2 \sum_{j=q+1}^p \lambda_j^{-1}$

引理3.3

若 $\hat{\beta}_{\text{PC}}$ 是主成分估计，则 $\text{MSE}(\hat{\beta}_{\text{PC}}) = \sigma^2 \sum_{j=1}^q \lambda_j^{-1} + \sum_{j=q+1}^p \alpha_j^2$

定理3.3

当设计矩阵存在多重共线性时，在均方误差的意义下，主成分估计优于最小二乘估计。

当存在多重共线性时，某些 $\lambda_j \approx 0$.

总结

- 主成分估计是有偏估计。
- 当存在多重共线性时，在均方误差的意义下，主成分估计优于最小二乘估计。

目录

3. 主成分回归 (Multicollinearity)

I. 主成分分析

II. 主成分估计

III. 主成分估计的性质

IV. 超参数选择

问题定义

- 假定 $\mathbf{X}^\top \mathbf{X}$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$, 其相应的单位正交特征向量为 $\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_p$ 。
- 由此, 可以构造主成分, 即

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j, j = 1, 2, \cdots, p$$

- 显然, 主成分至多有 p 个。
- 提问: 在主成分分析中, 如何确定主成分的个数 q ($q < p$) ?

实施方案

- 可以证明

$$\sum_{j=1}^p \lambda_j = p$$

- 称 $\frac{\lambda_j}{p}$ 为第 j 个主成分 z_j 的贡献率；称 $\sum_{j=1}^q \frac{\lambda_j}{p}$ 为前 q 个主成分的累积贡献率；
- 预先设置一个临界值 c_{PC} 。通常取值：70%、75%、80%。
- 选取 q 满足


$$\sum_{j=1}^{q-1} \lambda_j < c_{PC} \text{ 且 } \sum_{j=1}^q \lambda_j \geq c_{PC}$$

总结

- 假定 $\mathbf{X}^\top \mathbf{X}$ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$, 其相应的单位正交特征向量为 $\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_p$ 。
- 由此, 可以构造主成分, 即

$$\mathbf{z}_j = \mathbf{X}\mathbf{v}_j, j = 1, 2, \cdots, p$$

- 预设一个临界值 c_{PC} 。
- 选取合适的主成分个数 q , 使得累积贡献率超过临界值 c_{PC} 。



谢谢



SCHOOL OF DATA
SCIENCE & ENGINEERING
数据科学与工程学院